针对用户贷款情况进行预测

吴浩邦，刘俊麟，祝瑞

2019 年 5 月 31 日

Abstract

本次数据挖掘导论的期末作业我们选择的是 DataCastle 中的“用户贷款风险预测”。实验是根据题目所给出的每个用户的特征如用户的基本属性、银行流水、信用卡账单记录等等来建立准确的风险控制模型，以此来预测用户是否会逾期还款。由于数据规模较大，包含 7 万条数据，故先将数据进行特征值的筛选，而后使用 Xgboost 进行模型训练。

1 赛题分析

赛题内容：融 360 与平台上的金融机构合作，提供了近 7 万贷款用户的基本身份信息、消费行为、银行还款等数据信息，需要参赛者以此建立准确的风险控制模型，来预测用户是否会逾期还款。提供数据：参赛者可用的训练数据包括用户的基本属性 user_info.txt、银行流水记录 bank_detail.txt、用户浏览行为 browse_history.txt、信用卡账单记录 bill_detail.txt、放款时间 loan_time.txt，以及这些顾客是否发生逾期行为的记录 overdue.txt。（注意：并非每一位用户都有非常完整的记录，如有些用户并没有信用卡账单记录，有些用户却没有银行流水记录。）分析：题目是对用户进行预测，预测是否会逾期还款，并且通过题中给定的数据进行预测。题中提供了六个数据基本属性、银行流水记录、用户浏览行为、信用卡账单记录、放款时间；训练数据中提供顾客是否发生逾期行为的记录，测试数据中提供需要预测的顾客编号。通过对已有数据可视化并进行特征提取，判断哪些数据与逾期行为有关联，选择适应数据进行模型训练。并且用相应数据预测未知顾客的逾期行为。

2 数据初始化分析

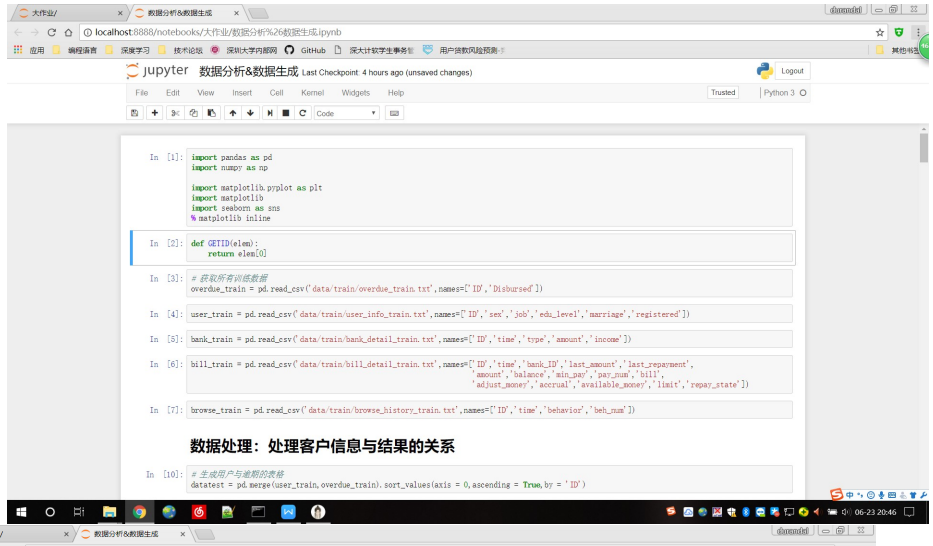

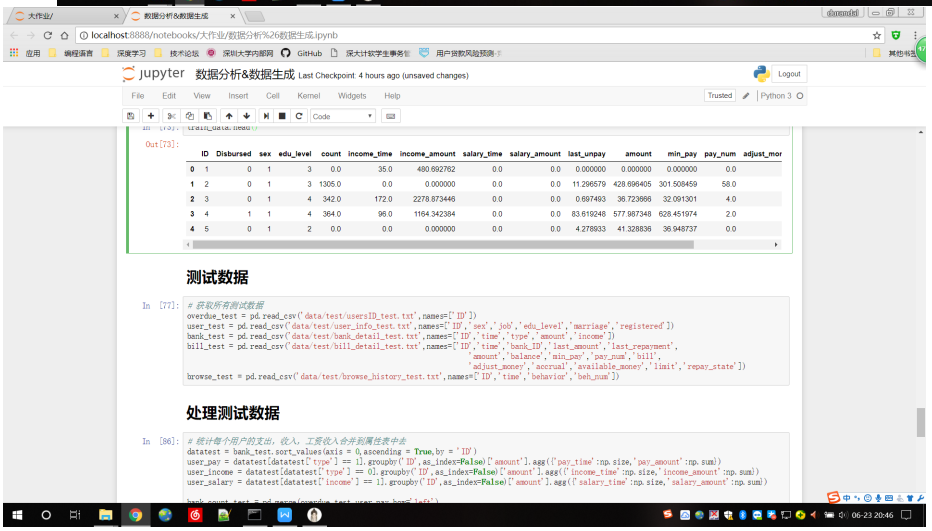

3 数据思路

3.1 基本思路

对题中提供的四个训练数据：基本属性、银行流水记录、用户浏览行为、信用卡账单记录选取全部或者部分进行按编号分组生成的数据集，并与是否发生逾期行为的记录进行合并，最后对合并后的数据集进行按逾期行为分组绘图，并通过可视化数据进行特征提取。

3.2 用户基本属性

```
    # 生成用户与逾期行为表格
datatest = pd.merge(user_train,overdue_train).sort_values(axis = 0,ascending
= True,by = 'ID')
# 计算每一个因素的逾期率
# 计算性别与逾期行为几率（以此类推往下）
sex_overdue = datatest.groupby('sex',as_index=False)['Disbursed'].agg('count':np.size,'num':np.sum)
sex_overdue['over_rate'] = sex_overdue['num']/sex_overdue['count']
# 计算职业与逾期行为几率
# 计算教育程度与逾期行为几率
# 计算婚姻状况与逾期行为几率
# 计算户口与逾期行为几率
```

3.3 银行流水记录

```
    # 统计每个用户的支出，收入，工资收入合并到属性表中去
# 计算用户支出总量
user_pay = datatest[datatest['type'] == 1].groupby('ID',as_index=False)['amount'].agg('pay_time':np.siz
# 计算用户收入总量
# 计算用户薪水总量
# 合并所有总量以及逾期行为并把无数据的用户的数据置零
bank_count = pd.merge(overdue_train,user_pay,how='left')
```

3.4 用户浏览行为

```
    # 按照用户编号分组计算浏览次数
browse_data = browse_train.groupby('ID',as_index=False)['ID'].agg('count':np.size)
# 合并总量以及逾期行为
browse_data = pd.merge(overdue_train,browse_data,how='left').sort_values
(axis = 0,ascending = True,by = 'ID') browse_data = browse_data.fillna(0)
```

3.5 信用卡账单记录

```
    # 获取上期未还金额, 计算方法：上期未还金额 = 上期账单 -上期还款
datatest = bill_train.copy()
# 上期未还金额不可为负
```

f = lambda x:x['last_amount']-x['last_repayment'] if x['last_amount']-x['last_repayment']>0 else 0 datatest['last_unpay'] = datatest.apply(f,axis=1)
# 计算上期未还金额
# 计算信用卡额度
# 计算本期最低还款额度
# 计算消费笔数
# 计算调整金额总数
# 计算循环利息
# 计算预借现金额度
# 合并总量以及逾期行为
bill_data = pd.merge(overdue_train,last_unpay,how='left').sort_values(axis = 0,ascending = True,by = 'ID')

4 数据特征值

选择训练数据：性别，教育程度，婚姻状况，收入总次数，收入金额总数，工资收入次数，工资收入总金额，浏览总数，信用卡额度，本期最低还款额，消费笔数，调整金额，利息，预借现金额度。以下为选择依据：

选择思路：对于每个数据都进行逾期行为的概率进行统计并绘图。

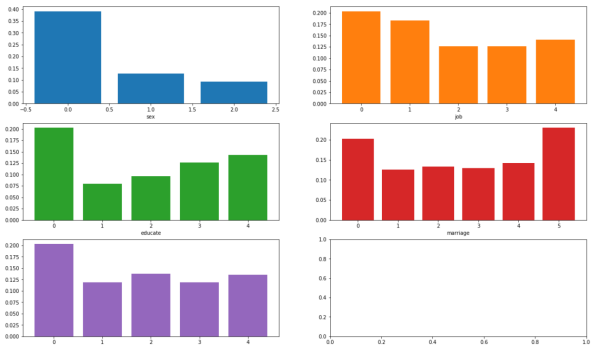

Figure 1: 性别、工作、教育程度、婚姻状况以及户籍的逾期行为比率柱形图

银行流水记录：
支出，收入，工资收入与是否逾期的关系

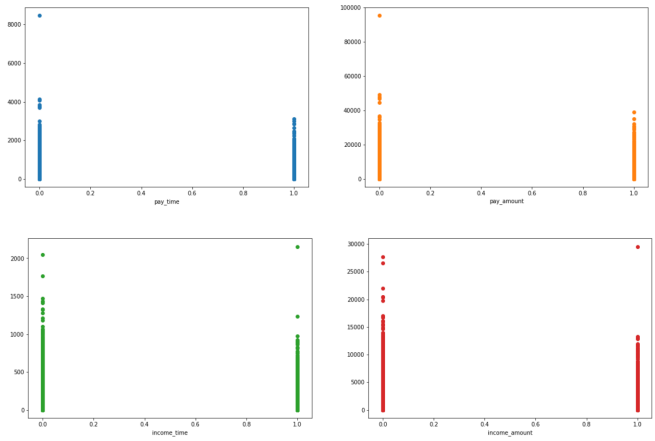

Figure 2: 付款次数和付款总额的逾期行为散点图

5 实验结果

使用 xgboost 算法对训练数据进行训练，使用生成的模型对测试数据进行预测，预测出每个用户的逾期率，并且提交结果得出比赛成绩。

6 总结

在数据分析中，我们先是查阅了大量的有关 xgboost 的原理文献，并对比 xgboost 所在的参数，如树的最大深度 max_depth)、随机森林数的数量 (n_estimators 等等进行一步步分析，其中收获最大的就是了解了 xgboost 的并行原理，它可以很“简单粗暴”的得到我们想要的结果，这在我以后应用数据挖掘中提到大量的帮助！根据后期查阅到的知识，xgboost 仅仅只能对单模型的数据具有快速强大的作用，并且需要对特征值进行融合，这一点我们虽然有做，但是没有排名前面融合的好。除了 xgboost 的特征融合，其实还有 mic 加权融合这种用不同模型，或者不同特征集、不同的样本集、不同的模型）的结果融合，可以有效的避免过拟合。

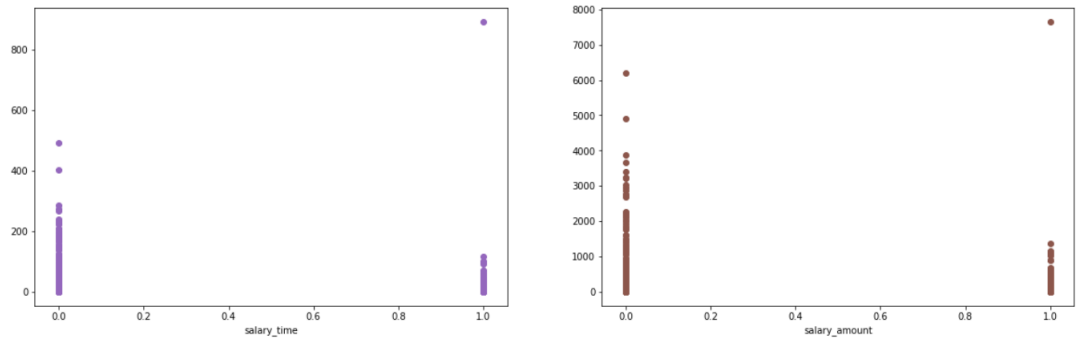

Figure 3: 薪水次数和薪水总额的逾期行为散点图

用户浏览行为：

浏览次数与逾期行为

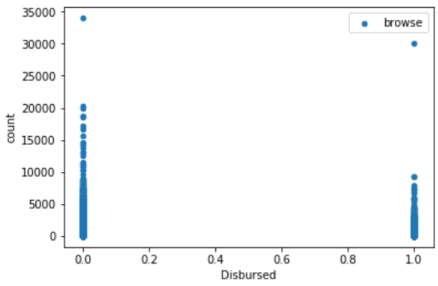

Figure 4: 浏览次数与逾期行为散点图

信用卡账单记录：

上期未还，信用卡额度，本期最低还款，消费总笔数，调整金额，循环利息，预借现金额度与是否逾期的关系

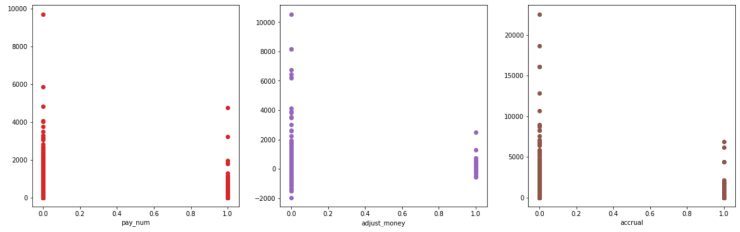

Figure 5: 上期未还、信用卡额度和本期最低还款与逾期行为散点图

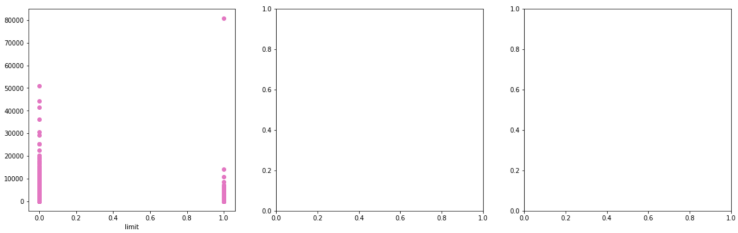

Figure 6: 消费总笔数、调整金额、循环利息与逾期行为散点图

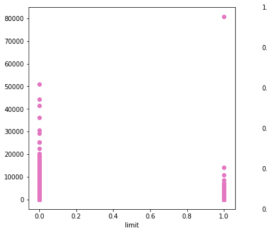

Figure 7: 预借现金额度与逾期行为散点图

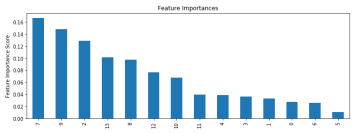

Figure 8: xgboost 算法数据特征关联结果

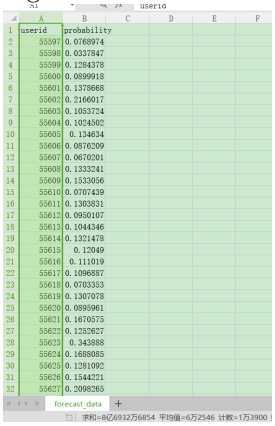

	A	B
1	userid	probability
2	55597	0.0769974
3	55598	0.0337847
4	55599	0.1284378
5	55600	0.0899918
6	55601	0.1378668
7	55602	0.2166017
8	55603	0.1053724
9	55604	0.1024502
10	55605	0.134634
11	55606	0.0876209
12	55607	0.0670201
13	55608	0.1333241
14	55609	0.1533056
15	55610	0.0707439
16	55611	0.1303831
17	55612	0.0950107
18	55613	0.1044346
19	55614	0.1321478
20	55615	0.12949
21	55616	0.111019
22	55617	0.1096887
23	55618	0.0703353
24	55619	0.1307078
25	55620	0.0895961
26	55621	0.1670575
27	55622	0.1252627
28	55623	0.343888
29	55624	0.1688085
30	55625	0.1281092
31	55626	0.1544221
32	55627	0.2098265

Figure 9: 生成预测百分比

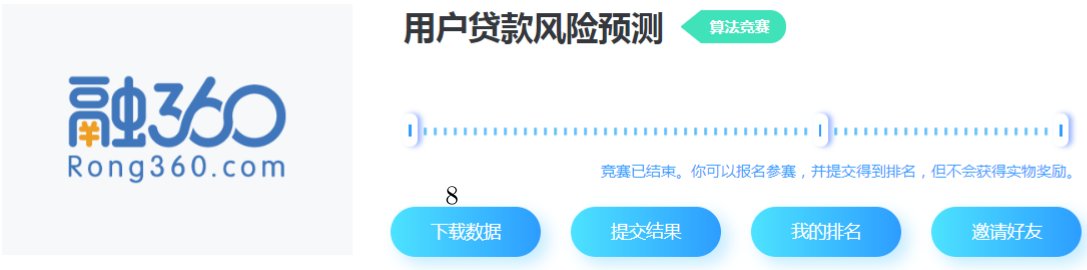

Figure 10: 竞赛成绩